

Template de Análise Exploratória de Dados (AED)

Guia completo no padrão HYPE — by Bernardo

Filosofia central: nenhum gráfico fica órfão. Toda plotagem, tabela ou número precisa de uma frase que **traduz** o que aquilo significa para o fenômeno estudado. O código mostra; você interpreta.

Setup inicial (sempre roda primeiro)

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

sns.set_theme(style="whitegrid")
pd.set_option("display.max_columns", None) # mostra todas as colunas
```

ETAPA 1 — Importação e primeira olhada

O que fazer: carregar o dataset e dar a primeira espiada para saber "com o que estou lidando".

Por que importa: você precisa saber o tamanho, as colunas e o formato antes de qualquer coisa.

```
df = pd.read_csv("seu_arquivo.csv")
df.head()          # 5 primeiras linhas
df.sample(5)       # 5 linhas aleatórias (melhor que head, evita viés do início)
```

Prompts de criticidade — responda no markdown:

- Quantas linhas e colunas tem? É um dataset grande ou pequeno?
- Qual é a **coluna alvo** (a que eu quereria prever num modelo)?
- As colunas fazem sentido? Alguma parece inútil (tipo um `id`)?

```
print("Dimensões:", df.shape)
print("\nColunas:", df.columns.tolist())
```

ETAPA 2 — Inspeção geral (a "ficha técnica")

O que fazer: entender tipos de dados, valores faltantes e estatísticas básicas.

```
df.info()          # tipos de cada coluna + contagem de não-nulos
df.describe()      # estatísticas das colunas NUMÉRICAS
df.describe(include="object") # estatísticas das colunas de TEXTO/categóricas
```

Como ler o `describe()`:

- `count` — quantos valores não-nulos

- `mean` — média
- `std` — desvio padrão (o quanto os dados variam)
- `min/max` — menor e maior valor
- `25%/50%/75%` — quartis (50% = mediana)

Prompts de criticidade:

- Alguma coluna numérica tem `max` absurdamente alto? (possível outlier ou erro)
 - A média e a mediana (50%) estão muito diferentes? (indica distribuição enviesada)
 - Algum tipo de dado está errado? (ex: idade como texto em vez de número)
-

ETAPA 3 — Tratamento dos dados (limpeza)

O que fazer: deixar os dados prontos para análise. Lixo entra, lixo sai.

3.1 Valores nulos

```
print(df.isnull().sum()) # conta nulos por coluna
```

Tratamentos possíveis:

```
# remover linhas com nulos (use se forem poucas)
df = df.dropna()

# preencher numérico com a mediana (mais robusta que a média a outliers)
df["coluna"] = df["coluna"].fillna(df["coluna"].median())

# preencher categórico com o valor mais comum (moda)
df["coluna"] = df["coluna"].fillna(df["coluna"].mode()[0])
```

Critério de decisão: se uma coluna tem >40% de nulos, considere remover a coluna inteira. Se são poucas linhas, remova as linhas.

3.2 Duplicatas

```
print("Duplicatas:", df.duplicated().sum())
df = df.drop_duplicates()
```

3.3 Padronização de texto (ANTES de mapear)

```
# remove espaços e padroniza maiúsculas – evita "Surgery" != "surgery "
df["coluna"] = df["coluna"].str.strip().str.title()
```

3.4 Conversão de categóricas para números (quando fizer sentido ordinal)

```
df["estagio"] = df["estagio"].map({
    "Stage I": 1, "Stage II": 2, "Stage III": 3, "Stage IV": 4
})
```

Prompts de criticidade:

- Os nulos eram aleatórios ou tinham padrão? (nulo às vezes é informação!)
 - Faz sentido transformar essa categoria em número? (só se houver ordem natural)
-

ETAPA 4 — Análise univariada (uma variável por vez)

O que fazer: entender a distribuição de cada variável isoladamente.

4.1 Variáveis numéricas → Histograma + Boxplot

```
# Histograma — mostra a FORMA da distribuição
plt.figure(figsize=(10, 5))
sns.histplot(data=df, x="age", bins=30, kde=True, color="steelblue")
plt.title("Distribuição de idade")
plt.xlabel("Idade")
plt.ylabel("Frequência")
plt.show()
```

Interprete: "a distribuição é simétrica/enviesada, com pico em torno de X. A maioria dos valores está entre Y e Z."

```
# Boxplot — mostra mediana, quartis e OUTLIERS
plt.figure(figsize=(8, 5))
sns.boxplot(data=df, y="age", color="steelblue")
plt.title("Boxplot de idade")
plt.show()
```

Interprete: "mediana em X; metade central dos dados entre Y e Z; há/não há outliers acima de W."

4.2 Variáveis categóricas → Countplot

```
plt.figure(figsize=(8, 5))
sns.countplot(data=df, x="gender", palette="Set2")
plt.title("Distribuição por gênero")
plt.show()
```

Interprete: "a base é equilibrada/desbalanceada entre as categorias."

ATENÇÃO — erro comum: só use hue quando a cor codificar uma variável com significado. Colorir cada barra diferente sem motivo (hue= 'age ' num histograma de idade) é poluição visual.

ETAPA 5 — Análise bivariada (CRUZAR com a coluna alvo)

Esta é a etapa mais importante. É onde você responde "o que explica o alvo?"

5.1 Categórica vs Alvo → Countplot com hue

```
plt.figure(figsize=(9, 5))
sns.countplot(data=df, x="cancer_stage", hue="survived", palette="rocket")
plt.title("Sobrevivência por estágio do câncer")
plt.xlabel("Estágio")
plt.ylabel("Contagem")
plt.legend(title="Sobreviveu", labels=["Não", "Sim"])
plt.show()
```

Interprete: "à medida que o estágio avança, a proporção de sobreviventes cai drasticamente — o estágio é fortemente explicativo."

5.2 Numérica vs Alvo → Boxplot separado por alvo

```
plt.figure(figsize=(9, 5))
sns.boxplot(data=df, x="survived", y="age", palette="Set2")
plt.title("Idade por sobrevivência")
plt.xticks([0, 1], ["Não sobreviveu", "Sobreviveu"])
plt.show()
```

Interprete: "sobreviventes tendem a ser mais jovens; a mediana difere em X anos."

5.3 Numérica vs Numérica → Scatterplot

```
plt.figure(figsize=(8, 6))
sns.scatterplot(data=df, x="age", y="bmi", hue="survived", alpha=0.6)
plt.title("Idade vs BMI, colorido por sobrevivência")
plt.show()
```

5.4 Mapa de correlação (todas as numéricas de uma vez)

```
num_cols = df.select_dtypes(include=np.number).columns
plt.figure(figsize=(10, 8))
sns.heatmap(df[num_cols].corr(), annot=True, cmap="coolwarm", center=0,
fmt=".2f")
plt.title("Correlação entre variáveis numéricas")
plt.tight_layout()
plt.show()
```

Como ler: valores perto de +1 (sobem juntas), perto de -1 (uma sobe outra desce), perto de 0 (sem relação). Procure o que mais se correlaciona com o alvo.

ETAPA 6 — Medidas descritivas direcionadas

O que fazer: quantificar com números o que os gráficos sugeriram.

```
# média de variáveis numéricas por grupo do alvo
df.groupby("survived")[["age", "bmi"]].mean()

# taxa do alvo por categoria (truque: média de 0/1 = proporção)
df.groupby("gender")["survived"].mean()

# várias estatísticas de uma vez
df.groupby("cancer_stage")["survived"].agg(["mean", "count"])
```

Prompts de criticidade:

- Os números confirmam o que o gráfico mostrou?
 - A diferença entre grupos é grande o suficiente para ser relevante?
-

ETAPA 7 — Conclusões (o fechamento crítico)

Regra de ouro: cada conclusão deve ter um NÚMERO e conectar ao fenômeno real.

Ruim: "a idade parece influenciar a sobrevivência" Bom: "sobreviventes têm idade média de 62 anos contra 67 dos não-sobreviventes — uma diferença de 5 anos, sugerindo que pacientes mais jovens respondem melhor ao tratamento"

Estrutura da conclusão:

1. Qual variável foi a MAIS explicativa do alvo? (com número)
 2. Qual variável surpreendeu por NÃO importar?
 3. Que hipótese de negócio/fenômeno isso sugere?
 4. O que faria diferente com mais tempo/dados?
-

CHECKLIST FINAL (padrão HYPE)

- ☐ Importação correta do dataset
- ☐ Inspeção geral (shape, info, describe)
- ☐ Tratamento (nulos, duplicatas, padronização)
- ☐ Seleção de linhas e colunas
- ☐ Filtro de linhas
- ☐ Plotagens de variáveis únicas (univariada)
- ☐ Plotagens de pares de variáveis (bivariada, direcionada ao alvo)
- ☐ Medidas descritivas
- ☐ Interpretação escrita em CADA plotagem
- ☐ Conclusão com números e hipóteses sobre o fenômeno